

Снижение размерности пространства в задачах декодирования сигналов

Исаченко Роман Владимирович

Диссертация на соискание ученой степени
кандидата физико-математических наук

05.13.17 – Теоретические основы информатики

Научный руководитель: д.ф.-м.н. В. В. Стрижов

Москва, 2021 г.

Снижение размерности пространства в задачах декодирования сигналов

Исследуется задача выбора модели при восстановлении скрытых зависимостей в исходном и в целевом пространствах.

Проблема

Целевая переменная – вектор, компоненты которого являются зависимыми. Гетерогенные пространства исходных и целевых переменных обладают существенно избыточной размерностью.



Требуется

Требуется построить модель, адекватно описывающую исходное и целевое пространства при наблюдаемой мультикорреляции в обоих пространствах.


Метод решения

Предлагается снизить размерность путём проецирования исходных и целевых переменных в скрытое пространство. Предлагаются линейные и нелинейные методы согласования прогностических моделей в пространствах высокой размерности.

Восстановление зависимости в исходном и целевом пространствах



Прогностическая модель декодирования



Согласование зависимостей в скрытом пространстве

$$\begin{array}{ccc}
 x \in \mathbb{R}^n & \xrightarrow{f} & y \in \mathbb{R}^r \\
 \searrow P & & \swarrow Q \\
 & t, u \in \mathbb{R}^\ell & \\
 x = Pt + \varepsilon_x & & \\
 y = Qu + \varepsilon_y & & \\
 \text{cov}(t, u) \rightarrow \max_{P, Q} & &
 \end{array}$$

Задача декодирования сигналов

$\mathbf{Y} = \mathbf{F}(\mathbf{X}, \boldsymbol{\Theta}) + \mathbf{E}_y = \mathbf{X} \cdot \boldsymbol{\Theta}^\top + \mathbf{E}_y$ – модель с параметрами $\boldsymbol{\Theta} \in \mathbb{R}^{r \times n}$.

Функция потерь модели декодирования

$$\mathcal{L}(f, \mathbf{X}, \mathbf{Y}) = \left\| \begin{matrix} \mathbf{Y} & \mathbf{X} & \boldsymbol{\Theta}^\top \\ m \times r & m \times n & r \times n \end{matrix} \right\|_2^2 \rightarrow \min_{\boldsymbol{\Theta}}; \quad \boldsymbol{\Theta}^\top = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Для устранения мультикорреляции столбцов матриц \mathbf{X} и \mathbf{Y} предлагается использовать методы снижения размерности пространства.

Метод проекции в скрытое пространство

$$\mathbf{X} = \mathbf{T} \cdot \mathbf{P}^\top + \mathbf{E}_x = \sum_{k=1}^{\ell} \mathbf{t}_k \cdot \mathbf{p}_k^\top + \mathbf{E}_x,$$

$$\mathbf{Y} = \mathbf{U} \cdot \mathbf{Q}^\top + \mathbf{E}_y = \sum_{k=1}^{\ell} \mathbf{u}_k \cdot \mathbf{q}_k^\top + \mathbf{E}_y.$$

$$\hat{\mathbf{Y}} = f(\mathbf{X}, \boldsymbol{\Theta}) = \mathbf{X}\boldsymbol{\Theta}, \quad \mathbf{U} \approx \mathbf{T}\mathbf{B}, \quad \mathbf{B} = \text{diag}(\beta_k), \quad \beta_k = \mathbf{u}_k^\top \mathbf{t}_k / (\mathbf{t}_k^\top \mathbf{t}_k).$$

Согласование

Метод проекции в скрытое пространство

Утверждение (Исаченко, 2017)

Вычисленные вектора \mathbf{t}_k и \mathbf{u}_k с помощью итеративной процедуры обновления:

$$\mathbf{t}_k := \frac{\mathbf{X}_k \mathbf{w}_k}{\|\mathbf{w}_k\|}, \quad \mathbf{w}_k := \mathbf{X}_k^\top \mathbf{u}_{k-1} / (\mathbf{u}_{k-1}^\top \mathbf{u}_{k-1});$$
$$\mathbf{u}_k := \frac{\mathbf{Y}_k \mathbf{c}_k}{\|\mathbf{c}_k\|}, \quad \mathbf{c}_k := \mathbf{Y}_k^\top \mathbf{t}_k / (\mathbf{t}_k^\top \mathbf{t}_k).$$

обладают максимальной ковариацией $\text{cov}(\mathbf{t}, \mathbf{u})$.

Теорема (Исаченко, 2017)

Параметры линейной модели проекции в скрытое пространство

$$\Theta = \mathbf{W}(\mathbf{P}^\top \mathbf{W})^{-1} \mathbf{B} \mathbf{Q}^\top, \quad \mathbf{T} = \mathbf{X} \mathbf{W}^*, \quad \text{где } \mathbf{W}^* = \mathbf{W}(\mathbf{P}^\top \mathbf{W})^{-1},$$

$$\mathbf{Y} = \mathbf{U} \mathbf{Q}^\top + \mathbf{E}_y \approx \mathbf{T} \mathbf{B} \mathbf{Q}^\top + \mathbf{E}_y = \mathbf{X} \mathbf{W}^* \mathbf{B} \mathbf{Q}^\top + \mathbf{E} = \mathbf{X} \Theta + \mathbf{E}_y,$$

доставляют максимум ковариации проекций $\text{cov}(\mathbf{t}, \mathbf{u})$.

Скрытое пространство в задаче декодирования

Особенностью задачи является избыточность размерности пространств описания переменных \mathbf{x} и \mathbf{y} . Требуется найти многообразия низкой размерности:

$$\begin{array}{ccc} \mathbf{X} \subset \mathbb{R}^n & \xrightarrow{\mathbf{f}} & \mathbf{Y} \subset \mathbb{R}^r \\ \phi_e \updownarrow \phi_d & & \psi_d \updownarrow \psi_e \\ \mathbf{T} \subset \mathbb{R}^\ell & \xrightarrow{\mathbf{h}} & \mathbf{U} \subset \mathbb{R}^s \end{array}$$

$\mathbf{T} \subset \mathbb{R}^\ell$ и $\mathbf{U} \subset \mathbb{R}^s$ *скрытые пространства* для $\mathbf{X} \in \mathbb{R}^n$ ($\ell \leq n$) и $\mathbf{Y} \in \mathbb{R}^r$ ($s \leq r$), если существуют *функции кодирования* $\phi_e : \mathbf{X} \rightarrow \mathbf{T}$, $\psi_e : \mathbf{Y} \rightarrow \mathbf{U}$ и *декодирования* $\phi_d : \mathbf{T} \rightarrow \mathbf{X}$, $\psi_d : \mathbf{U} \rightarrow \mathbf{Y}$:

для любого $\mathbf{x} \in \mathbf{X}$ существует $\mathbf{t} \in \mathbf{T} : \phi_d(\phi_e(\mathbf{x})) = \phi_d(\mathbf{t}) = \mathbf{x}$,

для любого $\mathbf{y} \in \mathbf{Y}$ существует $\mathbf{u} \in \mathbf{U} : \psi_d(\psi_e(\mathbf{y})) = \psi_d(\mathbf{u}) = \mathbf{y}$.

Скрытые пространства \mathbf{T} и \mathbf{U} называются *согласованными*, если существует *функция согласования* $\mathbf{h} : \mathbf{T} \rightarrow \mathbf{U}$:

$$\mathbf{y} = \mathbf{f}(\mathbf{x}) = \psi_d(\mathbf{h}(\phi_e(\mathbf{x}))).$$

Модель декодирования сигналов

Пусть $\mathbf{f}_1(\mathbf{x}_1, \Theta_1)$, $\mathbf{f}_2(\mathbf{x}_2, \Theta_2)$ – линейные модели декодирования сигналов.

Утверждение (Исаченко, 2021)

Пусть модель декодирования является аддитивной суперпозицией линейных моделей:

$$\mathbf{y} = \mathbf{f}_1(\mathbf{x}_1, \Theta_1) + \mathbf{f}_2(\mathbf{x}_2, \Theta_2) + \epsilon_y = \Theta_1 \mathbf{x}_1 + \Theta_2 \mathbf{x}_2 + \epsilon_y.$$

Тогда оптимальные параметры имеют вид

$$\Theta_1 = (\mathbf{X}_1^T \mathbf{M}_{\mathbf{X}_2} \mathbf{X}_1)^{-1} \mathbf{X}_1^T \mathbf{M}_{\mathbf{X}_2} \mathbf{Y},$$

$$\Theta_2 = (\mathbf{X}_2^T \mathbf{M}_{\mathbf{X}_1} \mathbf{X}_2)^{-1} \mathbf{X}_2^T \mathbf{M}_{\mathbf{X}_1} \mathbf{Y},$$

где $\mathbf{M}_{\mathbf{X}_1} = \mathbf{I} - \mathbf{X}_1(\mathbf{X}_1^T \mathbf{X}_1)^{-1} \mathbf{X}_1^T$, $\mathbf{M}_{\mathbf{X}_2} = \mathbf{I} - \mathbf{X}_2(\mathbf{X}_2^T \mathbf{X}_2)^{-1} \mathbf{X}_2^T$.

Теорема (Исаченко, 2021)



Если $\text{span}(\mathbf{X}_1) \neq \text{span}(\mathbf{X}_2)$, то ошибка аддитивной суперпозиции линейных моделей декодирования не превышает ошибки отдельной модели:

$$\mathcal{L}_{\text{dep}}(\Theta_1^*, \Theta_2^*, \mathbf{X}_1, \mathbf{X}_2, \mathbf{Y}) \leq \mathcal{L}(f_i, \mathbf{X}_i, \mathbf{Y}), \quad i = 1, 2.$$

Пример согласованной проекции в скрытое пространство

Исходные переменные $\mathbf{x}_i \sim \mathcal{N}(0, \Sigma)$.

Целевые переменные \mathbf{y}_i линейно зависят от pc_2 и не зависят от pc_1 .



Согласование проекций матриц \mathbf{X} и \mathbf{Y} позволяет найти оптимальное скрытое представление, отклоняя вектора \mathbf{w}_k и \mathbf{c}_k от направления главных компонент.

Нелинейные методы согласования скрытого пространства


Функции кодирования и декодирования являются глубокими нейросетями вида:

$$\mathbf{T} = \phi_e(\mathbf{X}) = \mathbf{W}_x^L \sigma(\dots \sigma(\mathbf{W}_x^2 \sigma(\mathbf{X} \mathbf{W}_x^1)) \dots)$$

$$\mathbf{U} = \psi_e(\mathbf{Y}) = \mathbf{W}_y^L \sigma(\dots \sigma(\mathbf{W}_y^2 \sigma(\mathbf{Y} \mathbf{W}_y^1)) \dots)$$

$$\mathbf{X} = \phi_d(\mathbf{T}) = \mathbf{W}_t^L \sigma(\dots \sigma(\mathbf{W}_t^2 \sigma(\mathbf{T} \mathbf{W}_t^1)) \dots)$$

$$\mathbf{Y} = \psi_d(\mathbf{U}) = \mathbf{W}_u^L \sigma(\dots \sigma(\mathbf{W}_u^2 \sigma(\mathbf{U} \mathbf{W}_u^1)) \dots)$$



Согласование проекций

Для нахождения оптимальной модели декодирования предложен метод согласования нелинейных проекций

$$g(\mathbf{T}, \mathbf{U}) \rightarrow \max_{\mathbf{W}}, \quad \mathbf{W} = \{\mathbf{W}_x^i, \mathbf{W}_y^i, \mathbf{W}_t^i, \mathbf{W}_u^i\}_{i=1}^L.$$

Выбор признаков в задаче декодирования

Требуется

Найти бинарный вектор $\mathbf{a} = \{0, 1\}^n$, компоненты – индикаторы выбранных признаков.

Функция ошибки отбора признаков

$$\mathbf{a} = \arg \min_{\mathbf{a}' \in \{0, 1\}^n} S(\mathbf{a}', \mathbf{X}, \mathbf{Y}).$$

Релаксация

Замена дискретной области определения $\{0, 1\}^n$ на непрерывную релаксацию $[0, 1]^n$:

$$\mathbf{z} = \arg \min_{\mathbf{z}' \in [0, 1]^n} S(\mathbf{z}', \mathbf{X}, \mathbf{Y}), \quad a_j = [z_j > \tau].$$

Получив \mathbf{a} , решаем задачу регрессии:

$$\mathcal{L}(\Theta_{\mathbf{a}}, \mathbf{X}_{\mathbf{a}}, \mathbf{Y}) = \left\| \mathbf{Y} - \mathbf{X}_{\mathbf{a}} \Theta_{\mathbf{a}}^T \right\|_2^2 \rightarrow \min_{\Theta_{\mathbf{a}}},$$

где индекс \mathbf{a} обозначает подматрицу с номерами столбцов, для которых $a_j = 1$.

Выбор признаков с помощью квадратичного программирования

$\mathbf{X} = [\chi_1, \dots, \chi_n] \in \mathbb{R}^{m \times n}$ – матрица объектов; $\mathbf{Y} = [\nu_1, \dots, \nu_r] \in \mathbb{R}^{m \times r}$ – матрица ответов

$$\|\nu - \mathbf{X}\theta\|_2^2 \rightarrow \min_{\theta \in \mathbb{R}^n}.$$

Задача квадратичного программирования

$$S(\mathbf{z}, \mathbf{X}, \nu) = (1 - \alpha) \cdot \underbrace{\mathbf{z}^T \mathbf{Q} \mathbf{z}}_{\text{Sim}(\mathbf{X})} - \alpha \cdot \underbrace{\mathbf{b}^T \mathbf{z}}_{\text{Rel}(\mathbf{X}, \nu)} \rightarrow \min_{\substack{\mathbf{z} \geq \mathbf{0}_n \\ \mathbf{1}_n^T \mathbf{z} = 1}}.$$

$\mathbf{z} \in [0, 1]^n$ – значимость признаков;

$\mathbf{Q} = [|\text{corr}(\chi_i, \chi_j)|]_{i,j=1}^n \in \mathbb{R}^{n \times n}$ – матрица парных взаимодействий признаков;

$\mathbf{b} = [|\text{corr}(\chi_i, \nu)|]_{i=1}^n \in \mathbb{R}^n$ – вектор релевантностей признаков к целевой переменной.

Утверждение (Исаченко, 2018)

Пусть матрица парных взаимодействий признаков $\hat{\mathbf{Q}}$ получена полуопределенной релаксацией исходной матрицы \mathbf{Q} :

$$\hat{\mathbf{Q}} = \mathbf{Q} - \lambda_{\min}(\mathbf{Q})\mathbf{I}.$$

Тогда задача выбора признаков с помощью квадратичного программирования имеет единственный глобальный минимум.

Выбор признаков в задаче декодирования

Агрегирование релевантностей по целевым векторам (RelAgg)

$$\mathbf{b} = [|\text{corr}(\chi_i, \nu)|]_{i=1}^n \rightarrow \mathbf{b} = \left[\sum_{k=1}^r |\text{corr}(\chi_i, \nu_k)| \right]_{i=1}^n.$$

Недостаток: нет учёта зависимостей в целевом пространстве матрицы \mathbf{Y} .

Симметричный учёт значимостей (SymImp)

Штрафуем коррелированные целевые вектора с помощью $\text{Sim}(\mathbf{Y})$:

$$S(\mathbf{z}, \mathbf{X}, \mathbf{Y}) = \alpha_1 \cdot \underbrace{\mathbf{z}_x^T \mathbf{Q}_x \mathbf{z}_x}_{\text{Sim}(\mathbf{X})} - \alpha_2 \cdot \underbrace{\mathbf{z}_x^T \mathbf{B} \mathbf{z}_y}_{\text{Rel}(\mathbf{X}, \mathbf{Y})} + \alpha_3 \cdot \underbrace{\mathbf{z}_y^T \mathbf{Q}_y \mathbf{z}_y}_{\text{Sim}(\mathbf{Y})} \rightarrow \min_{\substack{\mathbf{z}_x \geq \mathbf{0}_n, \mathbf{1}_n^T \mathbf{z}_x = 1 \\ \mathbf{z}_y \geq \mathbf{0}_r, \mathbf{1}_r^T \mathbf{z}_y = 1}},$$

$$\mathbf{Q}_x = [|\text{corr}(\chi_i, \chi_j)|]_{i,j=1}^n, \quad \mathbf{Q}_y = [|\text{corr}(\nu_i, \nu_j)|]_{i,j=1}^r, \quad \mathbf{B} = [|\text{corr}(\chi_i, \nu_j)|]_{\substack{i=1,\dots,n, \\ j=1,\dots,r}}$$

$$\alpha_1 + \alpha_2 + \alpha_3 = 1, \quad \alpha_i \geq 0.$$

Выбор признаков в задаче декодирования

SymImp штрафует коррелированные целевые вектора, которые в меньшей мере объясняются признаками.

$$\alpha_1 \cdot \underbrace{\mathbf{z}_x^T \mathbf{Q}_x \mathbf{z}_x}_{\text{Sim}(\mathbf{X})} - \alpha_2 \cdot \underbrace{\mathbf{z}_x^T \mathbf{B} \mathbf{z}_y}_{\text{Rel}(\mathbf{X}, \mathbf{Y})} \rightarrow \min_{\substack{\mathbf{z}_x \geq \mathbf{0}_n \\ \mathbf{1}_n^T \mathbf{z}_x = 1}} ; \quad \alpha_3 \cdot \underbrace{\mathbf{z}_y^T \mathbf{Q}_y \mathbf{z}_y}_{\text{Sim}(\mathbf{Y})} + \alpha_2 \cdot \underbrace{\mathbf{z}_x^T \mathbf{B} \mathbf{z}_y}_{\text{Rel}(\mathbf{X}, \mathbf{Y})} \rightarrow \min_{\substack{\mathbf{z}_y \geq \mathbf{0}_r \\ \mathbf{1}_r^T \mathbf{z}_y = 1}} .$$

Минимаксный подход (MinMax / MaxMin)

$$S(\mathbf{z}, \mathbf{X}, \mathbf{Y}) = \min_{\substack{\mathbf{z}_x \geq \mathbf{0}_n \\ \mathbf{1}_n^T \mathbf{z}_x = 1}} \max_{\substack{\mathbf{z}_y \geq \mathbf{0}_r \\ \mathbf{1}_r^T \mathbf{z}_y = 1}} \left(\text{or } \max_{\substack{\mathbf{z}_y \geq \mathbf{0}_r \\ \mathbf{1}_r^T \mathbf{z}_y = 1}} \min_{\substack{\mathbf{z}_x \geq \mathbf{0}_n \\ \mathbf{1}_n^T \mathbf{z}_x = 1}} \right) \left[\alpha_1 \cdot \underbrace{\mathbf{z}_x^T \mathbf{Q}_x \mathbf{z}_x}_{\text{Sim}(\mathbf{X})} - \alpha_2 \cdot \underbrace{\mathbf{z}_x^T \mathbf{B} \mathbf{z}_y}_{\text{Rel}(\mathbf{X}, \mathbf{Y})} - \alpha_3 \cdot \underbrace{\mathbf{z}_y^T \mathbf{Q}_y \mathbf{z}_y}_{\text{Sim}(\mathbf{Y})} \right] .$$

Теорема (Исаченко, 2018)

Для положительно определенных матриц \mathbf{Q}_x и \mathbf{Q}_y minmax и maxmin задачи достигают одинакового значения функционала $S(\mathbf{z}, \mathbf{X}, \mathbf{Y})$

Теорема (Исаченко, 2018)

Минимаксная задача эквивалентна задаче квадратичного программирования с $n + r + 1$ переменными.

Для получения выпуклой задачи применяется полуопределенная релаксация сдвига спектра.

Выбор признаков в задаче декодирования

Максимизация релевантностей (MaxRel)

$$S(\mathbf{z}, \mathbf{X}, \mathbf{Y}) = \min_{\substack{\mathbf{z}_x \geq \mathbf{0}_n \\ \mathbf{1}_n^\top \mathbf{z}_x = 1}} \max_{\substack{\mathbf{z}_y \geq \mathbf{0}_r \\ \mathbf{1}_r^\top \mathbf{z}_y = 1}} \left(\text{or } \max_{\substack{\mathbf{z}_y \geq \mathbf{0}_r \\ \mathbf{1}_r^\top \mathbf{z}_y = 1}} \min_{\substack{\mathbf{z}_x \geq \mathbf{0}_n \\ \mathbf{1}_n^\top \mathbf{z}_x = 1}} \right) \left[(1 - \alpha) \cdot \mathbf{z}_x^\top \mathbf{Q}_x \mathbf{z}_x - \alpha \cdot \mathbf{z}_x^\top \mathbf{B} \mathbf{z}_y \right].$$

Теорема (Исаченко, 2018)

Для положительно определенной матрицы \mathbf{Q}_x $\min\max$ и $\max\min$ задачи достигают одинакового значения функционала $S(\mathbf{z}, \mathbf{X}, \mathbf{Y})$.

Асимметричный учёт значимостей (AsymImp)

$$\alpha_1 \cdot \underbrace{\mathbf{z}_x^\top \mathbf{Q}_x \mathbf{z}_x}_{\text{Sim}(\mathbf{X})} - \alpha_2 \cdot \underbrace{\left(\mathbf{z}_x^\top \mathbf{B} \mathbf{z}_y - \mathbf{b}^\top \mathbf{z}_y \right)}_{\text{Rel}(\mathbf{X}, \mathbf{Y})} + \alpha_3 \cdot \underbrace{\mathbf{z}_y^\top \mathbf{Q}_y \mathbf{z}_y}_{\text{Sim}(\mathbf{Y})} \rightarrow \min_{\substack{\mathbf{z}_x \geq \mathbf{0}_n, \mathbf{1}_n^\top \mathbf{z}_x = 1 \\ \mathbf{z}_y \geq \mathbf{0}_r, \mathbf{1}_r^\top \mathbf{z}_y = 1}}.$$

При $b_j = \max_{i=1, \dots, n} [\mathbf{B}]_{i,j}$ коэффициенты при \mathbf{z}_y в $\text{Rel}(\mathbf{X}, \mathbf{Y})$ неотрицательны.

Обобщение предложенных методов выбора признаков

Теорема (Исаченко, 2018)

В одномерном случае $r = 1$ предлагаемые методы выбора признаков *SymImp*, *MinMax*, *MaxRel*, *AsymImp* совпадают с исходной задачей минимизации функции ошибок $S(\mathbf{z}, \mathbf{X}, \mathbf{Y})$.

Алгоритм	Критерий	Функция ошибки $S(\mathbf{z}, \mathbf{X}, \mathbf{Y})$
RelAgg	$\min [\text{Sim}(\mathbf{X}) - \text{Rel}(\mathbf{X}, \mathbf{Y})]$	$\min_{\mathbf{z}_x} [(1 - \alpha) \cdot \mathbf{z}_x^T \mathbf{Q}_x \mathbf{z}_x - \alpha \cdot \mathbf{z}_x^T \mathbf{B} \mathbf{1}_r]$
SymImp	$\min [\text{Sim}(\mathbf{X}) - \text{Rel}(\mathbf{X}, \mathbf{Y}) + \text{Sim}(\mathbf{Y})]$	$\min_{\mathbf{z}_x, \mathbf{z}_y} [\alpha_1 \cdot \mathbf{z}_x^T \mathbf{Q}_x \mathbf{z}_x - \alpha_2 \cdot \mathbf{z}_x^T \mathbf{B} \mathbf{z}_y + \alpha_3 \cdot \mathbf{z}_y^T \mathbf{Q}_y \mathbf{z}_y]$
MinMax	$\min [\text{Sim}(\mathbf{X}) - \text{Rel}(\mathbf{X}, \mathbf{Y})]$ $\max [\text{Rel}(\mathbf{X}, \mathbf{Y}) + \text{Sim}(\mathbf{Y})]$	$\min_{\mathbf{z}_x} \max_{\mathbf{z}_y} [\alpha_1 \cdot \mathbf{z}_x^T \mathbf{Q}_x \mathbf{z}_x - \alpha_2 \cdot \mathbf{z}_x^T \mathbf{B} \mathbf{z}_y - \alpha_3 \cdot \mathbf{z}_y^T \mathbf{Q}_y \mathbf{z}_y]$
MaxRel	$\min [\text{Sim}(\mathbf{X}) - \text{Rel}(\mathbf{X}, \mathbf{Y})]$ $\max [\text{Rel}(\mathbf{X}, \mathbf{Y})]$	$\min_{\mathbf{z}_x} \max_{\mathbf{z}_y} [(1 - \alpha) \cdot \mathbf{z}_x^T \mathbf{Q}_x \mathbf{z}_x - \alpha \cdot \mathbf{z}_x^T \mathbf{B} \mathbf{z}_y]$
AsymImp	$\min [\text{Sim}(\mathbf{X}) - \text{Rel}(\mathbf{X}, \mathbf{Y})]$ $\max [\text{Rel}(\mathbf{X}, \mathbf{Y}) + \text{Sim}(\mathbf{Y})]$	$\min_{\mathbf{z}_x, \mathbf{z}_y} [\alpha_1 \mathbf{z}_x^T \mathbf{Q}_x \mathbf{z}_x - \alpha_2 (\mathbf{z}_x^T \mathbf{B} \mathbf{z}_y - \mathbf{b}^T \mathbf{z}_y) + \alpha_3 \mathbf{z}_y^T \mathbf{Q}_y \mathbf{z}_y]$

Внешние критерии качества решения задачи декодирования

Нормированное RMSE

Качество прогнозирования:

$$\text{sRMSE}(\mathbf{Y}, \hat{\mathbf{Y}}_a) = \sqrt{\frac{\text{MSE}(\mathbf{Y}, \hat{\mathbf{Y}}_a)}{\text{MSE}(\mathbf{Y}, \bar{\mathbf{Y}})}} = \frac{\|\mathbf{Y} - \hat{\mathbf{Y}}_a\|_2}{\|\mathbf{Y} - \bar{\mathbf{Y}}\|_2}, \quad \text{где} \quad \hat{\mathbf{Y}}_a = \mathbf{X}_a \Theta_a^\top.$$

$\bar{\mathbf{Y}}$ — константный прогноз.

Мультикорреляция

Среднее значение коэффициента множественной корреляции:



$$R^2 = \frac{1}{r} \text{tr}(\mathbf{C}^\top \mathbf{R}^{-1} \mathbf{C}), \quad \mathbf{C} = [\text{corr}(\chi_i, \nu_j)]_{i=1, \dots, n, j=1, \dots, r}, \quad \mathbf{R} = [\text{corr}(\chi_i, \chi_j)]_{i,j=1}^n.$$

Байесовский информационный критерий

Компромисс между качеством предсказания и числом выбранных признаков $\|\mathbf{a}\|_0$:

$$\text{BIC} = m \ln(\text{MSE}(\mathbf{Y}, \hat{\mathbf{Y}}_a)) + \|\mathbf{a}\|_0 \cdot \log m.$$

Задача декодирования сигналов электрокортикограммы



Заданы:


$\mathbf{X} \in \mathbb{R}^{m \times (32 \cdot 27)}$ – сигналы ECoG,

$\mathbf{Y} \in \mathbb{R}^{m \times 3k}$ – траектория движения руки, где

$$\mathbf{Y} = \begin{pmatrix} x_1 & y_1 & z_1 & \dots & x_k & y_k & z_k \\ x_2 & y_2 & z_2 & \dots & x_{k+1} & y_{k+1} & z_{k+1} \\ \dots & \dots & \dots & & \dots & \dots & \dots \\ x_m & y_m & z_m & \dots & x_{m+k} & y_{m+k} & z_{m+k} \end{pmatrix}.$$


Столбцы матрицы \mathbf{Y} сильно скоррелированы по временной оси.

<http://neurotycho.org>





Матрица корреляций \mathbf{Y}

Анализ предложенных методов выбора признаков



Предложены методы выбора модели, имеющей меньшую ошибку по отношению к базовому алгоритму.

Сравнение метода проекции в скрытое пространство с методами выбора признаков



- ▶ Предлагаемые методы выбора признаков достигают меньшей ошибки по сравнению с базовыми алгоритмами Lasso и Elastic.
- ▶ PLS показывает сравнимое качество с QPFS.
- ▶ Комбинация двух алгоритмов показывает наилучший результат.

Результаты, выносимые на защиту

1. Исследована проблема снижения размерности сигналов в пространствах высокой размерности. Предложены методы декодирования сигналов, учитывающие зависимости как в исходном, так и в целевом пространстве сигналов.
2. Доказаны теоремы об оптимальности предлагаемых методов декодирования сигналов. Предлагаемые методы позволяют осуществлять выбор согласованных моделей в случае избыточной размерности описания данных.
3. Предложены методы выбора признаков, учитывающие зависимости как в исходном, так и в целевом пространстве. Предложенные алгоритмы доставляют устойчивые и адекватные решения в коррелированных пространствах высокой размерности.
4. Предложены нелинейные методы согласования скрытых пространств для данных со сложноорганизованной целевой переменной.
5. Предложен ряд моделей для прогнозирования гетерогенных наборов сигналов для задачи построения нейрокомпьютерных интерфейсов.

Список работ автора по теме диссертации

Публикации ВАК

1. Isachenko R., Strijov V. Quadratic Programming Feature Selection for Multicorrelated Signal Decoding with Partial Least Squares *Expert Systems with Applications*, 2021, на рецензировании.
2. Исаченко Р.В., Яушев Ф.Р., Стрижов В.В. Модели согласования скрытого пространства в задаче прогнозирования // Системы и средства информатики, 31(1), 2021.
3. Isachenko R., Vladimirova M., Strijov V. Dimensionality Reduction for Time Series Decoding and Forecasting Problems. *DEStech Transactions on Computer Science and Engineering*, optim, 2018.
4. Isachenko R., Strijov V. Quadratic programming optimization for Newton method. *Lobachevskii Journal of Mathematics*, 39(9), 2018.
5. Isachenko R. et al. Feature Generation for Physical Activity Classification. *Artificial Intelligence and Decision Making*, 3, 2018.
6. Исаченко Р.В., Стрижов В. В. Метрическое обучение в задачах мультиклассовой классификации временных рядов *Информатика и её применения*, 10(2), 2016.

Выступления с докладом

1. Intelligent Data Processing Conference, 2020, Снижение размерности в задаче декодирования временных рядов.
2. Intelligent Data Processing Conference, 2018, Dimensionality reduction for multicorrelated signal decoding with projections to latent space.
3. Математические методы распознавания образов, 2017. Локальные модели для классификации объектов сложной структуры.
4. Intelligent Data Processing Conference, 2016. Multimodel forecasting multiscale time series in internet of things.
5. Ломоносов, 2016. Метрическое обучение в задачах мультиклассовой классификации временных рядов.